Факторизація методом пробних дільників у PARCS-Python

Звіт з лабораторної роботи № 1 з дисципліни «Хмарні обчислення»

Петров Богдан Вікторович, група МІ-41

Київ — 2026

Зміст

1. Ідея алгоритму . . . 1
   Послідовний варіант . . . 1
   Паралельний варіант . . . 2
   Тестові дані . . . 2
2. Як влаштовано PARCS-Python . . . 2
3. Кластер у хмарі . . . 3
4. Демонстрація роботи . . . 3
   Вузли master і worker . . . 3
   Виконання алгоритму на 1, 2, 3 і 4 воркерах . . . 4
5. Результати . . . 5
   У хмарі (Hetzner Cloud) . . . 5
   Локально (для порівняння) . . . 6
6. Build-проблеми та як їх виправлено . . . 7
7. Як повторити . . . 8
   У Hetzner Cloud . . . 8
   Локально в Docker Compose . . . 8
   У Google Cloud . . . 9
8. Висновки . . . 10
9. Посилання . . . 10

Лабораторна робота № 1 з дисципліни «Хмарні обчислення». Тема 6.3 — факторизація методом пробних дільників. Платформа — PARCS-Python, розгортання — кластер master + N worker у хмарі Hetzner Cloud (і локально в Docker Compose).

- Код розв'язку: `solution.py`
- Виправлений PARCS-Python (Dockerfile, залежності): `parcs-python/`
- Скрипти: `benchmark.py`, `plot.py`, `hetzner/`
- Результати: `results/`
- Звіт у PDF: `report/report.pdf`

1. Ідея алгоритму

Послідовний варіант

Метод пробних дільників перевіряє кандидатів d = 2, 3, 5, 7, … доти, поки $d^2 \le n$. Якщо n ділиться на d, то d — простий множник (усі менші прості вже поділені), його виносять, n зменшується, а

межа $\sqrt{n}$ зменшується разом з ним. Те, що залишилось від n після перевірки всіх кандидатів до $\sqrt{n}$, — просте число (або 1). Складність — $O(\sqrt{n})$ ділень; для добутку двох близьких простих $p \cdot q$ (найгірший випадок) потрібно перебрати всі непарні кандидати до p.

Паралельний варіант

Перевірка кожного кандидата не залежить від інших, тому діапазон кандидатів можна різати на шматки і перевіряти їх на різних вузлах.

1. **Master** читає список чисел. Для кожного n він спочатку виносить двійки (щоб далі перевіряти лише непарні кандидати), рахує межу `isqrt(n)` і ріже діапазон `[3, isqrt(n)]` на шматки по `CHUNK = 2 000 000` непарних кандидатів (≈0,4 с роботи). Шматки всіх чисел стають у одну чергу «по колу»: k-й шматок кожного числа йде перед (k+1)-м шматком будь-якого.
2. **Worker** отримує `(n, lo, hi)` і повертає всі непарні d з `[lo, hi)`, для яких `n % d == 0`. Це єдина функція, яка виконується на робочому вузлі (`find_divisors`, позначена `@expose`).
3. **Динамічний розподіл.** Master викликає воркерів асинхронно (Pyro4 повертає future), тримає по одному активному шматку на кожного воркера і, щойно якийсь воркер звільнився, віддає йому наступний шматок із черги. Ніхто не чекає на інших, навантаження вирівнюється саме собою.
4. **Збирання результату.** Отримані дільники master сортує і ділить n по зростанню. Складений дільник (наприклад 15 = 3·5) теж буде повернений, але до моменту, коли черга дійде до нього, 3 і 5 уже винесені, тому `n % 15 != 0` і він пропускається. Коли всі шматки числа перевірені, залишок $n > 1$ додається як останній простий множник.
5. **Відсікання.** Після знайденого множника межа $\sqrt{n}$ зменшується, і шматки, що починаються за новою межею, видаляються з черги. Шматки, які вже виконуються, дораховуються — зайві дільники нешкідливі. Завдяки порядку «по колу» в момент знахідки на воркерах крутиться щонайбільше один-два шматки цього числа, тож марної роботи майже немає навіть на 12 воркерах.

Обсяг роботи однаковий для будь-якої кількості воркерів (той самий набір кандидатів), тому прискорення — це просто відношення часів. Великі числа передаються як рядки, щоб не впиратись у серіалізатор Pyro4.

Тестові дані

`gen_input.py --count 8 --lo 200000000 --hi 500000000` детерміновано генерує 8 напівпростих чисел $p \cdot q$ з простими p, q з проміжку $[2 \cdot 10^8, 5 \cdot 10^8)$ (`input.txt`). Для них пробні дільники мають перебрати $\approx 1{,}32 \cdot 10^9$ непарних кандидатів сумарно (≈660 викликів воркерів) — це найгірший випадок для методу, тому обсяг роботи не залежить від випадку і від кількості воркерів.

2. Як влаштовано PARCS-Python

Кластер складається з головного вузла (**master**, вебінтерфейс на порту 8080) і робочих вузлів (**worker**), які реєструються на master за HTTP і раз на 5 с перевіряються heartbeat'ом. Користувач через вебсторінку (або `POST /api/job`) завантажує `solution.py` та вхідний файл. Master розсилає `solution.py` усім воркерам, кожен воркер піднімає Pyro4-сервер з об'єктом `Solver`, а master створює `Solver(workers, input, output)` і викликає `solve()`. Методи з декоратором `@expose` викликаються на воркерах через `self.workers[i].метод(...)`; виклик асинхронний і повертає future з полями `ready` та `value`.

3. Кластер у хмарі

PARCS розгорнуто в Hetzner Cloud (локація Гельсінкі) на трьох віртуальних машинах CX23: 2 vCPU, 4 ГБ пам'яті, Ubuntu 24.04. Машини з'єднані приватною мережею `10.10.0.0/24`.

Вузол	Приватна адреса	Публічна адреса	Що запущено
`parcs-master`	10.10.0.2	89.167.57.71	master, вебінтерфейс на порту 8080
`parcs-worker1`	10.10.0.4	немає	2 процеси worker, кожен на своєму vCPU
`parcs-worker2`	10.10.0.5	немає	2 процеси worker, кожен на своєму vCPU

Проєкт Hetzner обмежений п'ятьма серверами, тому чотири воркери розміщено на двох машинах по два. Worker у PARCS однопотоковий, тож один процес на ядро використовує машину повністю. Кожен процес реєструється на master як окремий вузол зі своїм портом.

Як це влаштовано:

- публічну адресу має лише master; воркери виходять в інтернет через нього (NAT), а по SSH до них заходять стрибком через master;
- вузли спілкуються приватною мережею: воркер реєструється на master за адресою `10.10.0.2:8080`, а master викликає воркерів через Pyro4 за їхніми приватними адресами;
- вебінтерфейс PARCS не має входу і виконує будь-який завантажений код, тому хмарний фаєрвол пропускає ззовні тільки SSH, а інтерфейс відкривається через SSH-тунель;
- усе створює і видаляє один скрипт, `hetzner/cluster.py`, через Hetzner Cloud API.

Список машин, як його бачить Hetzner API (`python3 hetzner/cluster.py status`):

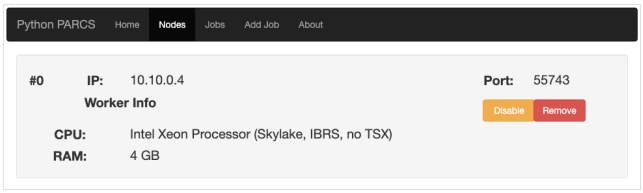
```
NAME            STATUS    TYPE   PUBLIC IP        PRIVATE IP
parcs-master    running   cx23   89.167.57.71     10.10.0.2
parcs-worker1   running   cx23   -                10.10.0.4
parcs-worker2   running   cx23   -                10.10.0.5
```

4. Демонстрація роботи

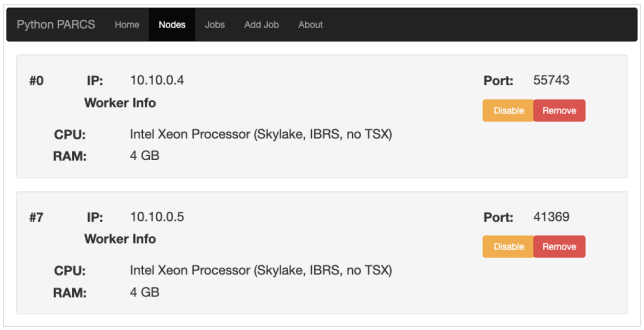
Вузли master і worker

Сторінка Nodes вебінтерфейсу master при одному, двох, трьох і чотирьох воркерах. Воркери з адресою 10.10.0.4 працюють на `parcs-worker1`, з адресою 10.10.0.5 на `parcs-worker2`. Кількість воркерів змінюється зупинкою і запуском процесів worker; зупинений воркер master сам прибирає зі списку після пропущеного heartbeat.

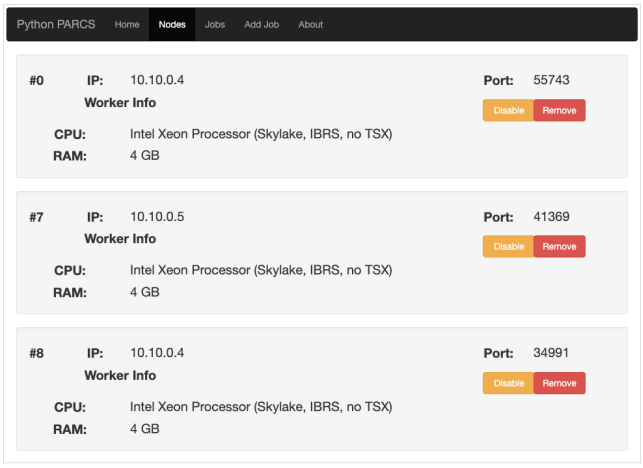
1 воркер



2 воркери



3 воркери



4 воркери

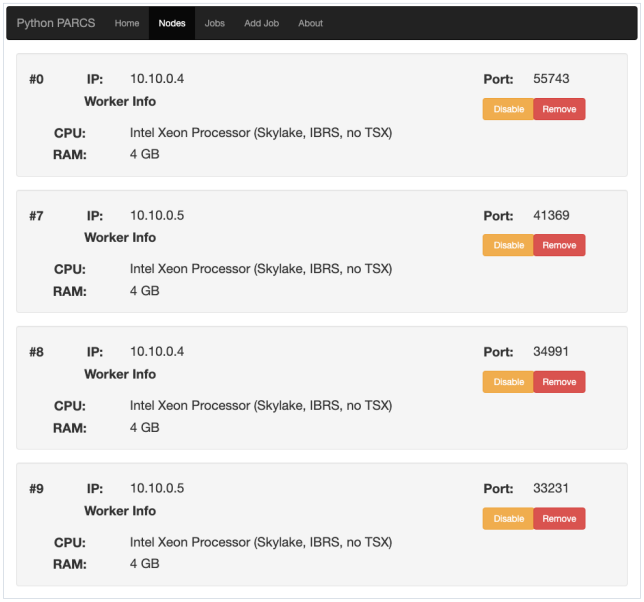


Рис. 1: Вузли кластера при 1, 2, 3 і 4 воркерах

Виконання алгоритму на 1, 2, 3 і 4 воркерах

Одне й те саме завдання (`solution.py` і `input.txt`: вісім 18-значних чисел) запущено по три рази для кожної кількості воркерів.

Воркери	Де працюють	Час трьох запусків, с	Викликів воркерів
1	worker1	149,9; 153,9; 151,8	664
2	worker1, worker2	82,4; 83,1; 83,0	664–665
3	worker1 (два процеси), worker2	54,8; 55,8; 54,3	665–666
4	worker1 і worker2, по два процеси	44,0; 44,2; 43,4	667–669

Останній рядок вихідного файлу для кожної кількості воркерів:

```
workers: 1, calls: 664, time: 151.83 s
workers: 2, calls: 665, time: 83.03 s
workers: 3, calls: 666, time: 54.32 s
workers: 4, calls: 668, time: 43.44 s
```

Сторінка Jobs: кожен запуск має час старту, тривалість і посилання на код, вхідний та вихідний файли.

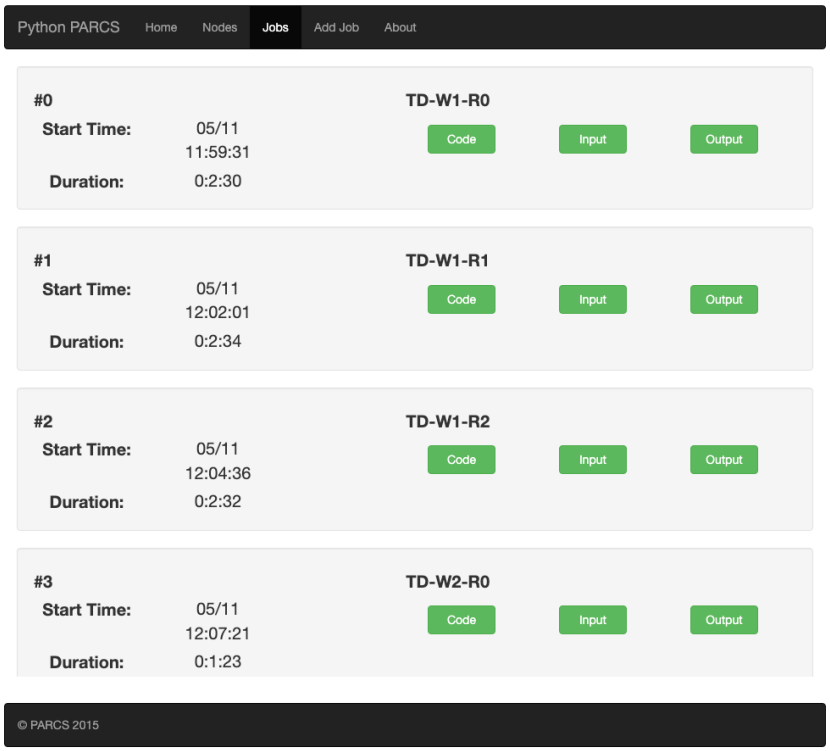


Рис. 2: Задачі у вебінтерфейсі PARCS

Повний вихідний файл запуску на чотирьох воркерах (`results/cloud/output_w4.txt`): усі вісім чисел розкладено на два простих множники.

```
66759158378966927 = 250535683 * 266465669
203973952226415737 = 429561871 * 474841847
146781283389103213 = 382601801 * 383639813
171913215010764229 = 413619691 * 415631119
85388716748642543 = 244552069 * 349163747
128551009856156273 = 325271357 * 395211589
140700008367405887 = 350011687 * 401986601
64305656657855251 = 243238579 * 264372769
workers: 4, calls: 668, time: 43.44 s
```

5. Результати

У хмарі (Hetzner Cloud)

Умови: кластер із розділу 3, вхід `input.txt` (8 напівпростих, близько $1{,}32 \cdot 10^9$ кандидатів). Для кожної кількості воркерів зроблено 3 запуски (`./hetzner/bench.sh 4 3`). Час береться з вихідного файлу розв'язку: він вимірюється на master від початку `solve()` до запису результату. Сирі дані: `results/results_cloud.csv`, лог: `results/cloud_benchmark.log`.

Воркери	Час, с (сер.)	min / max, с	Прискорення	Ефективність
1	151.9	149.9 / 153.9	1.00	1.00
2	82.8	82.4 / 83.1	1.83	0.92

Воркери	Час, с (сер.)	min / max, с	Прискорення	Ефективність
3	54.9	54.3 / 55.8	2.76	0.92
4	43.9	43.4 / 44.2	3.46	0.87

Прискорення — час на одному воркері, поділений на час на k воркерах; ефективність — прискорення, поділене на k.

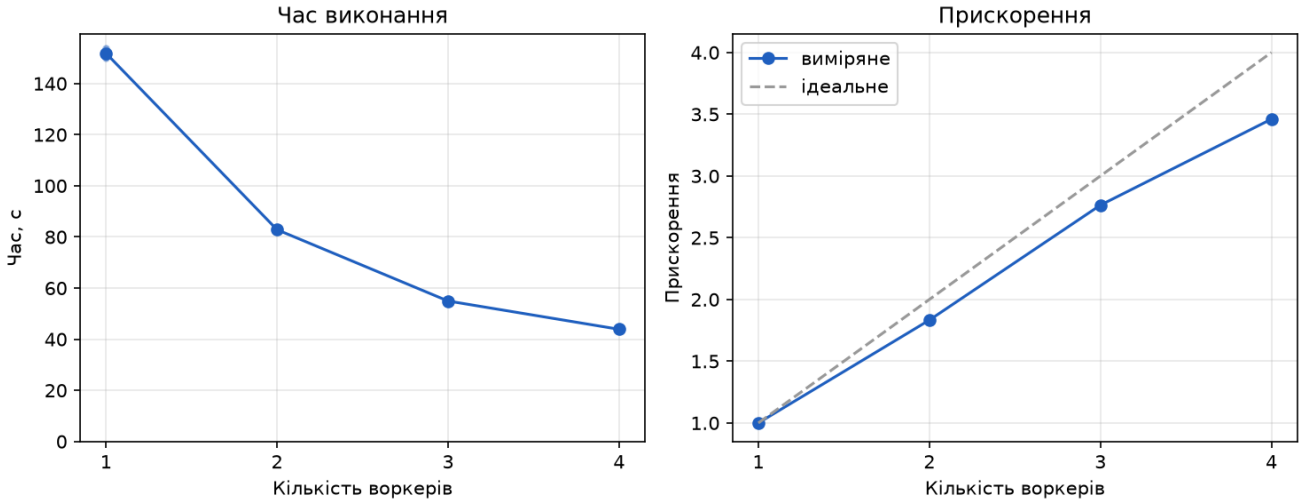


Рис. 3: Час виконання і прискорення в хмарі

Чотири воркери рахують у 3,46 раза швидше за один, розкид між запусками менший за 3%. Кількість викликів воркерів майже не росте з їх числом (664 на одному, 668 на чотирьох): відсікання і порядок «по колу» працюють, марної роботи менше 1%.

Прискорення трохи нижче ідеального з простої причини: віртуальні машини неоднакові. Окремий замір показав, що `parcs-worker1` перевіряє близько 7,2 млн кандидатів за секунду, а `parcs-worker2` близько 5,5 млн. Перший воркер, з яким порівнюємо, працює на швидшій машині, тому два воркери разом дають 12,7 / 7,2 = 1,76 від його швидкості, а чотири 3,53. Виміряні 1,83 і 3,46 збігаються з цим очікуванням: динамічний розподіл шматків сам вирівнює навантаження між швидшими й повільнішими вузлами.

Локально (для порівняння)

Той самий вхід на ноутбуці Apple M4 Pro у Docker Compose, кожен контейнер обмежено одним ядром. Сирі дані: `results/results.csv`.

Воркери	Час, с (сер.)	min / max, с	Прискорення	Ефективність
1	215.3	211.1 / 218.0	1.00	1.00
2	104.9	97.0 / 113.6	2.05	1.03
4	61.6	59.5 / 64.0	3.50	0.87
8	61.4	54.8 / 65.5	3.51	0.44

Рядок для 8 воркерів показує обмеження машини, а не алгоритму: під час вимірювань інша програма займала близько п'яти ядер, тому вісім контейнерів ділили ті самі чотири-п'ять вільних. Хмарні вимірювання цього недоліку не мають.

6. Build-проблеми та як їх виправлено

Оригінальний репозиторій Hummer12007/parcs-python не оновлювався з 2019 року, і зібрати його «як є» вже не можна. Готовий образ `hummer12007/parcs-node` з Docker Hub (2018 рік) досі працює на amd64-машинах GCE, але на Apple Silicon він запускається лише через емуляцію і значно повільніший. Тому образ зібрано заново — папка `parcs-python/` містить оригінальний код із такими правками:

Проблема	Прояв	Виправлення
`FROM debian:stretch-slim` — Debian 9 знято з підтримки, репозиторії видалено	`apt-get update` дає `404 Not Found`, `E: Failed to fetch …/dists/stretch/main/binary-amd64/Packages`	Базовий образ `python:2.7.18-slim`; apt взагалі не використовується
Ядро PARCS написано лише під Python 2 (`imp`, `ConfigParser`, `Queue`, `Pyro4.async` — у Python ≥ 3.7 `async` є ключовим словом і дає `SyntaxError`)	Порт на Python 3 означав би переписати ядро	Залишено Python 2.7.18 (останній 2.x)
`requirements.txt` без версій: сучасні Flask 2/3, Jinja2 3, Werkzeug 2, click 8, serpent 1.30.2 — лише для Python 3	`pip install` падає: `No matching distribution found for serpent==1.30.2`, або Flask імпортується з помилкою	Зафіксовано останні версії з підтримкою 2.7: Pyro4 4.82, serpent 1.28, Flask 1.1.4, Werkzeug 1.0.1, Jinja2 2.11.3, MarkupSafe 1.1.1, itsdangerous 1.1.0, click 7.1.2, requests 2.27.1, py-cpuinfo 5.0.0
`netifaces` — C-розширення, для py2.7/arm64 немає wheel, потрібен gcc і заголовки Python	збирання падає на `error: command 'gcc' failed`	`network_utils.get_ip()` переписано через `socket` (UDP-connect без надсилання даних); залежність видалено
`py-cpuinfo` ≥ 6 перейменував ключ `brand` на `brand_raw`	`KeyError: 'brand'` при старті вузла	Версія зафіксована і код читає будь-який із ключів із fallback на `platform.machine()`
Heartbeat від master до worker без `timeout` у `requests.get`	Після зупинки воркера (VM або контейнера) master «зависає» на TCP-з'єднанні до мертвої IP на ~2 хв на кожного воркера; список вузлів оновлюється лише через кілька хвилин, наступна задача стартує із затримкою	`timeout=5` у heartbeat (`parcs_py/node.py`); мертвий воркер зникає зі списку за ~20 с
Вузол реєструється з першою адресою машини (`hostname -I`), у хмарі це публічна адреса	Master не може достукатися до воркера через приватну мережу, або трафік іде назовні	Змінна `PARCS_IP` у `generate_config.sh` задає адресу, з якою вузол реєструється

Проблема	Прояв	Виправлення
Образ лише для amd64	На Apple Silicon — попередження про platform mismatch і емуляція	GitHub Actions збирає multi-arch образ (amd64 + arm64) і публікує в `ghcr.io/aiavenger1/parcs-node`

Після цього `docker build parcs-python/` проходить без apt і компілятора приблизно за 10 секунд.

7. Як повторити

У Hetzner Cloud

Потрібні акаунт Hetzner Cloud, SSH-ключ, доданий у проєкт, і API-токен з правами Read & Write (консоль Hetzner, Security, API tokens).

```
echo '<токен>' > ~/.hcloud-token
chmod 600 ~/.hcloud-token

# мережа, фаєрвол, master і дві воркерні машини
python3 hetzner/cluster.py up --workers 2

# NAT, Docker, збирання образу, запуск вузлів
python3 hetzner/cluster.py provision --per-vm 2

# тунель до вебінтерфейсу: команду друкує сам скрипт
python3 hetzner/cluster.py tunnel
open http://localhost:8081/workers

# 1..4 воркери, по 3 запуски, потім таблиця і графік
./hetzner/bench.sh 4 3
python3 plot.py results/results_cloud.csv _cloud

# видалити все створене і зупинити оплату
python3 hetzner/cluster.py down
```

Скрипт чіпає лише ресурси з міткою `project=parcs-lab1`. Три машини CX23 коштують разом близько 0,03 євро за годину.

Локально в Docker Compose

```
git clone https://github.com/AIAvenger1/parcs-trial-division.git
cd parcs-trial-division

# master + 4 workers, список вузлів
docker compose up -d --build --scale worker=4
open http://localhost:8080/workers

# один запуск вручну: Add Job, файли solution.py та input.txt, результат у Jobs.
# Або весь бенчмарк: сам масштабує воркерів, 3 запуски на кожну кількість
python3 benchmark.py --workers 1 2 4 8 --runs 3
uv run --with matplotlib python3 plot.py

docker compose down
```

У `docker-compose.yml` кожному контейнеру виділено рівно 1 CPU (`cpus: 1`), тому N воркерів справді означає N ядер. Порт 8080 прив'язано лише до `127.0.0.1`: вебінтерфейс PARCS виконує будь-який завантажений код і не має автентифікації, тож назовні його відкривати не можна.

У Google Cloud

Те саме можна розгорнути в Google Compute Engine за методичкою курсу; команди нижче підготовлені, але в цій роботі не запускалися.

Потрібні: акаунт GCP з увімкненим білінгом (вистачає безкоштовного кредиту) і встановлений gcloud CLI.

```
# 0. вхід і проєкт
gcloud auth login
gcloud projects create parcs-lab-<ваше-прізвище>
gcloud config set project parcs-lab-<ваше-прізвище>
gcloud services enable compute.googleapis.com
gcloud config set compute/zone europe-central2-a

# 1. фаєрвол: вебінтерфейс PARCS лише з вашої IP
gcloud compute firewall-rules create parcs-ui \
  --direction=INGRESS --network=default --action=ALLOW --rules=tcp:8080 \
  --source-ranges="$(curl -s https://api.ipify.org)/32" \
  --target-tags=parcs-master

# 2. master
gcloud compute instances create-with-container master \
  --machine-type=e2-small --tags=parcs-master \
  --container-image=ghcr.io/aiavenger1/parcs-node:latest \
  --container-env=PARCS_ARGS="master"
MASTER_INT=$(gcloud compute instances describe master \
  --format='get(networkInterfaces[0].networkIP)')
MASTER_EXT=$(gcloud compute instances describe master \
  --format='get(networkInterfaces[0].accessConfigs[0].natIP)')

# 3. воркери (без зовнішніх IP — їм потрібен лише master)
gcloud compute instances create-with-container worker1 worker2 worker3 worker4 \
  --machine-type=e2-medium --no-address \
  --container-image=ghcr.io/aiavenger1/parcs-node:latest \
  --container-env=PARCS_ARGS="worker $MASTER_INT"

# 4. перевірка: через ~1 хв усі воркери видно тут
open "http://$MASTER_EXT:8080/workers"

# 5. бенчмарк: кількість воркерів змінюємо зупинкою і запуском VM
M="http://$MASTER_EXT:8080"
./gcp/scale.sh 1 && python3 benchmark.py --master $M --no-scale --workers 1
./gcp/scale.sh 2 && python3 benchmark.py --master $M --no-scale --workers 2
./gcp/scale.sh 4 && python3 benchmark.py --master $M --no-scale --workers 4

# 6. не забути вимкнути: видаляє всі VM і правило фаєрволу
./gcp/destroy.sh
```

Те саме одним скриптом: `WORKERS=4 ./gcp/deploy.sh` (кроки 1–3), `./gcp/scale.sh N`, `./gcp/destroy.sh`. Замість `ghcr.io/aiavenger1/parcs-node` можна вказати оригінальний `registry.hub.docker.com/hummer12007/parcs-node` — на amd64-машинах GCE він працює без перезбирання.

Корисне: `gcloud compute instances list`, `gcloud compute ssh master`, всередині `docker ps`, `docker logs <container>`; `gcloud compute instances stop/start worker3`.

8. Висновки

Факторизацію методом пробних дільників реалізовано в PARCS-Python як динамічний розподіл шматків діапазону дільників між воркерами з відсіканням після кожного знайденого множника. Оригінальний образ PARCS-Python перезібрано на сучасній базі (Python 2.7.18, зафіксовані залежності, без apt і компілятора), додано timeout у heartbeat і вибір адреси вузла. Кластер розгорнуто в Hetzner Cloud однією командою: приватна мережа, публічна адреса лише в master, вебінтерфейс доступний тільки через SSH-тунель. На чотирьох воркерах у хмарі задача виконується у 3,46 раза швидше, ніж на одному, за 44 секунди замість 152.

9. Посилання

- Репозиторій: https://github.com/AIAvenger1/parcs-trial-division
- PARCS-Python (оригінал): https://github.com/Hummer12007/parcs-python
- Методичка курсу: PARCS-Python & Google Compute Engine (mi.csc.knu.ua, 09.2025)
- Hetzner Cloud API: https://docs.hetzner.cloud